

Proyecto Final: Telecomunicaciones: identificar a los operadres ineficaces

1. Objetivo

El objetivo del presente proyecto es identificar operadores ineficientes dentro del servicio de telefonía virtual CallMeMaybe mediante el análisis exploratorio de datos, la creación de métricas operativas y la validación de resultados a través de pruebas estadísticas.

Se busca detectar patrones de bajo desempeño en los operadores con base en indicadores clave como llamadas perdidas, tiempos de espera y volúmenes de llamadas salientes.

2. Descripción de los datos

Para el análisis se utilizaron dos conjuntos de datos:

- telecom_dataset_us.csv
- telecom_clients_us.csv

Las variables más relevantes para el análisis fueron:

- operador_id
- direction
- internal
- is_missed_call
- calls_count
- call_duration
- total_call_duration

3. Hipótesis del análisis

Hipótesis 1

- H0: No hay diferencia significativa en la proporción de llamadas entrantes perdidas entre operadores eficientes e ineficientes.
- H1: Los operadores ineficientes tienen una proporción significativamente mayor de llamadas entrantes perdidas.

Hipótesis 2

- H0: No hay diferencia significativa en el tiempo promedio de espera de llamadas entrantes entre operadores eficientes e ineficientes.
- H1: Los operadores ineficientes tienen un tiempo promedio de espera significativamente mayor.

Hipótesis 3

- H0: Entre operadores que realizan llamadas salientes, no hay diferencia significativa en el volumen de llamadas salientes entre operadores eficientes e ineficientes.

- H1: Entre operadores que realizan llamadas salientes, los operadores ineficientes realizan significativamente menos llamadas salientes.

4. Limpieza de datos

Se realizó un proceso de limpieza y validación de los datos:

- Eliminación de registros duplicados (4900 filas)
- Tratamiento de valores nulos en operator_id (rellenar con -1)
- Conversión de variables a tipos adecuados (fechas y enteros)
- Verificación de consistencia:
 - No se encontraron duraciones negativas
 - La duración de llamada siempre es menor o igual al total

Las llamadas sin operador fueron analizadas en el EDA general, pero se excluyeron al evaluar desempeño individual, ya que no pueden atribuirse a un operador específico.

5. Análisis exploratorio de datos (EDA)

Se realizó un análisis exploratorio para entender el comportamiento general de las llamadas:

- Duración de llamadas: la distribución presenta un sesgo importante, por lo que se aplicó una transformación logarítmica.
- Distribución de llamadas: se observó una mayor proporción de llamadas salientes en comparación con las entrantes.
- Llamadas internas vs externas: más del 90% de las llamadas son externas, indicando que la operación está enfocada principalmente en la atención al cliente.
- Llamadas perdidas: existe un volumen considerable de llamadas no atendidas, lo cuál impacta directamente la calidad del servicio.

6. Definición de operadores ineficientes

Se definió a un operador como ineficiente con base a tres indicadores clave:

- Alta tasa de llamadas perdidas (missed_rate)
- Alto tiempo de espera (avg_waiting_time)
- Bajo número de llamadas salientes (outgoing_calls)

Para establecer los umbrales se utilizaron percentiles con el fin de enfocar el análisis en el grupo de operadores con desempeño más extremo dentro de la distribución:

- Percentil P75 para identificar valores altos (peor desempeño)
- Percentil P25 para identificar valores bajos (baja actividad)

A partir de estos umbrales, se generaron variables binarias:

- high_missed_rate: indica si el operador presenta una tasa de llamadas perdidas superior al umbral.

- `high_waiting_time`: indica si el tiempo de espera es superior al umbral.
- `low_outgoing_calls`: indica si el número de llamadas salientes es inferior al umbral (considerando únicamente operadores con actividad saliente).

Posteriormente, se construyó un índice de ineficiencia (`inefficiency_score`) mediante la suma de estas condiciones:

- Cada condición cumplida suma 1 punto
- El puntaje total varía de 0 a 3

Finalmente, un operador fue clasificado como ineficiente cuando:
 $\text{inefficiency_score} \geq 2$

Para evitar sesgos, el criterio de bajo volumen de llamadas salientes se aplicó únicamente a operadores con actividad saliente.

7. Resultados del análisis

Los resultados obtenidos muestran una clara diferencia entre operadores eficientes e ineficientes:

- Los operadores ineficientes presentan mayores tasas de llamadas perdidas.
- Presentan tiempo de espera significativamente más alto.
- Tienden a realizar un menor número de llamadas salientes.

En el análisis visual, los operadores ineficientes se concentran en zonas de alto tiempo de espera y alta tasa de llamadas perdidas.

8. Pruebas de hipótesis

Se aplicó la prueba no paramétrica Mann-Whitney U para comparar el desempeño de operadores eficientes e ineficientes.

Hipótesis evaluadas:

- Los operadores ineficientes tienen mayor tasa de llamadas perdidas.
- Los operadores ineficientes presentan mayor tiempo de espera.
- Los operadores ineficientes realizan menor número de llamadas salientes.

Resultados:

En todos los casos se obtuvo un $p\text{-value} < 0.05$, por lo tanto, se rechaza la hipótesis nula.

9. Conclusiones

El análisis permitió identificar patrones claros de ineficiencia en los operadores. Se identificó que los operadores ineficientes tienden a concentrarse en niveles bajos de actividad, lo cual puede estar relacionado con factores operativos o de capacitación.

10. Recomendaciones

Con base en los resultados obtenidos, se proponen las siguientes acciones:

- Optimizar la asignación de llamadas para equilibrar la carga de trabajo.
- Monitorear los tiempos de espera.
- Implementar programas de capacitación para operadores con alta tasa de llamadas perdidas.
- Establecer indicadores de desempeño para seguimiento operativo.
- Incentivar la actividad en llamadas salientes.

11. Dashboards

Link para visualizar Dashboards:

https://public.tableau.com/views/ProyectoFinalTelecomunicaciones/Dashboard2?:language=es-ES&:sid=&:redirect=auth&:display_count=n&:origin=viz_share_link

12. Fuentes

Pandas – Crosstab Function

<https://interactivechaos.com/es/python/function/pandascrosstab>

Utilizada para el análisis de relaciones entre variables categóricas mediante tablas de contingencia.

Artículo: Data Cleaning in Python – Handling Duplicates and Missing Values

<https://medium.com/womenintechology/data-cleaning-in-python-dealing-with-duplicates-and-missing-values-with-the-3-aces-up-the-sleeve-70b63eb4c0b9>

Utilizado como referencia para el proceso de limpieza de datos, manejo de valores nulos y eliminación de duplicados.

NumPy – Average Function

<https://numpy.org/doc/2.2/reference/generated/numpy.average.html>

Utilizada para comprender el cálculo de promedios ponderados en el análisis de datos.

Artículo: Python Lambda Functions – Real Python

<https://realpython.com/python-lambda/>

Utilizado para comprender el uso de funciones lambda en transformaciones y operaciones sobre datos.

Discusión: Kaggle – Data Analysis Practices

<https://www.kaggle.com/discussions/general/545428>

Utilizada como referencia complementaria sobre prácticas comunes en análisis de datos y enfoque exploratorio.

Artículo: Third Quartile (Q3) – Statistics By Jim

<https://statisticsbyjim.com/glossary/third-quartile/>

Utilizado para la interpretación de percentiles y su aplicación en la identificación de valores extremos.

SciPy Documentation – Mann-Whitney U Test

<https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.mannwhitneyu.html>

Utilizada para la aplicación de pruebas estadísticas no paramétricas en la comparación de grupos.

Artículo: Tableau Bins – Hevo Data

<https://hevodata.com/learn/tableau-bins/>

Utilizado para la comprensión de la creación de bins e histogramas en Tableau.